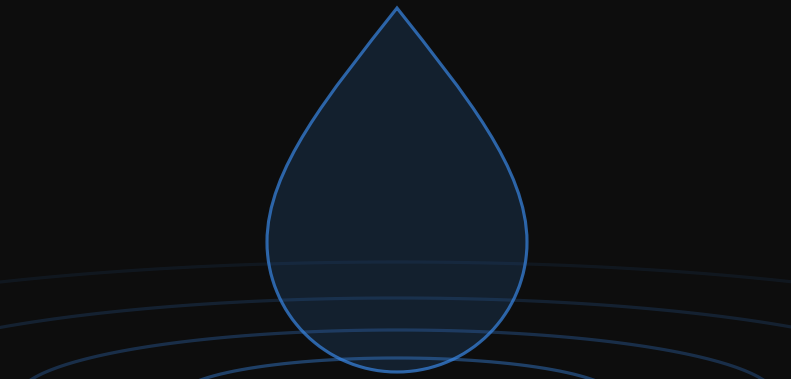
Vertiente

Track **Datos y Streaming** · Desafío QualyData

HACKATHON ARGENTINA SPACE 2026 · SALTA

Vertiente

Qué circula, desde cuándo y quién lo empuja.
Narrativas y coordinación a escala, explicables y baratas.



github.com/Shugar03/vertiente

Sebastián Paz · Francisco Fernández · Antonio Chocobar

DOMINGO 06-09 · 01:12

«Ya van a cortar la cinta en campaña aunque no haya ni camas.»

01:12

aparece un rumor nuevo

Narrativa emergente

24

cuentas empiezan a empujarlo en el mismo minuto

Operación op03

1 día

de antigüedad tienen esas cuentas activas 100% de madrugada

El rumor estaba escondido entre 200.000 comentarios

Dos preguntas: ¿qué narrativas circulan? y ¿qué parte es genuina y qué parte está armada?

IA COMENTARIO POR COMENTARIO

Lenta y cara

200.000 llamadas a un modelo por corrida, y aun así no ve la coordinación.

PALABRAS CLAVE

No generalizan

La gente dice lo mismo de mil maneras y el set final trae otros temas.

COORDINACIÓN

Es invisible de a uno

Solo aparece mirando el conjunto: quién, dónde, cuándo y cuántas veces.

TAREA A · NARRATIVAS

Descubrirlas sin lista previa, asignar cada comentario o marcarlo como ruido, decir si **apoya o rechaza** y cuándo nació.

TAREA B · COORDINACIÓN

Detectar las cuentas que actúan coordinadas y **agruparlas por operación**, sin confundirlas con picos virales genuinos.

IDEA 1

La conversación misma es la etiqueta

APOYA · N00 «EL AGUA ES PARA LA GENTE, NO PARA LA MINA»

Primero el agua de la población, después el litio.

↳ **RECHAZA · RESPONDE CON UN ARGUMENTO**

CHE, MENTIRA QUE LA MINA DEJA SIN AGUA AL PUEBLO, USAN AGUA SALADA QUE NO ES PARA CONSUMO.

↳ **RECHAZA · ACOMPAÑA Y HEREDA**

100% de acuerdo

- Una respuesta **siempre** es de la misma narrativa: 28.054 de 28.054.
- El 80% discute desde la **postura opuesta**.
- Uniendo respuestas, las narrativas y sus dos bandos aparecen **solos**: sin lista previa ni etiquetado.
- Embeddings locales solo de textos únicos (200k → 62k).

Medido en E03–E06 (experimentos/)

IDEA 2

Una operación se delata por la repetición



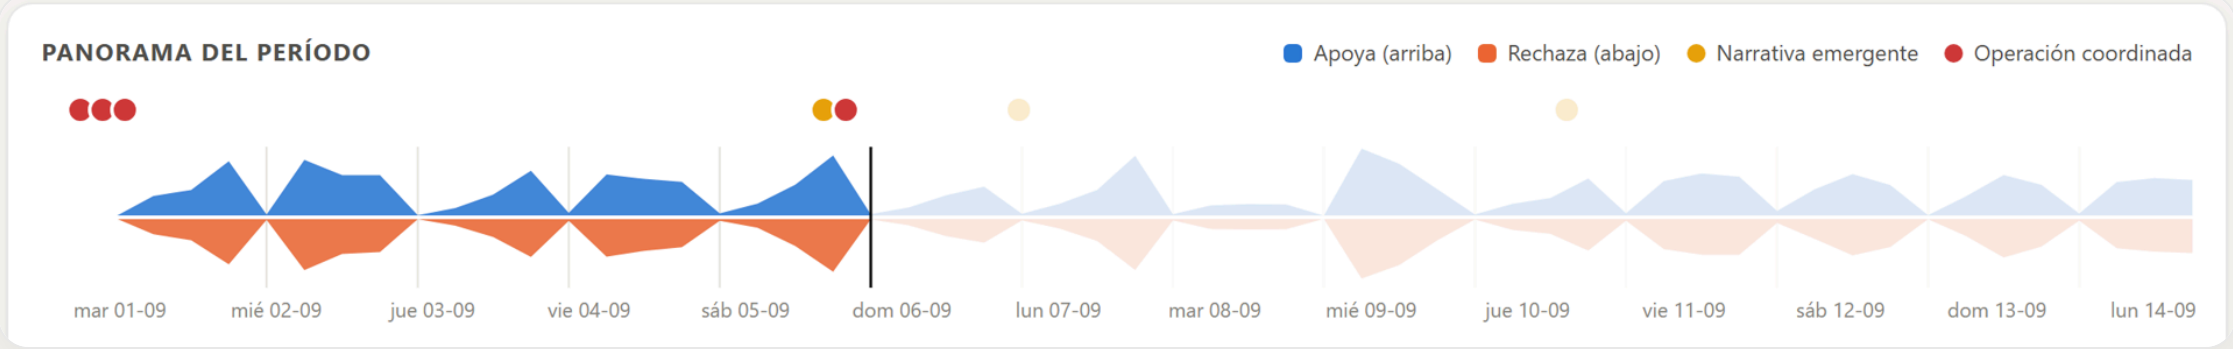
- Sincronía **alineada**: misma publicación, misma narrativa y postura, a minutos.
- Repetida en **varias** publicaciones; el azar no forma triángulos.
- Picos virales y usuarios intensivos **no pasan** (hay un test que lo verifica).
- Todo en SQL: 3,3 M pares de cuentas en menos de 3 s.

Medido en E08–E30 (experimentos/)

DEMO · EL PERÍODO EN VIVO

Qué circula, desde cuándo y quién lo empuja

mar 01-09



Narrativa emergente · dom 06-09 01:12

«Ya van a cortar la cinta en campaña aunque no haya ni camas»

op03 · en el mismo minuto

24 cuentas creadas el día anterior, activas 100% de madrugada, empujan el rumor.

No toma partido

op01: ~60 cuentas a favor del proyecto · **op02**: cuentas antiguas en contra.

Narrativas **30** + Coordinación **25** · automático

SET DE PRÁCTICA · SCRIPT OFICIAL

53,6 /55

Línea base oficial del desafío: ≈ **17**

NARRATIVAS · 29,70 / 30

Agrupamiento (B-cubed)	**0,991**
Ruido (F1)	**0,970**
Postura (macro-F1)	**0,995**
Origen emergentes	**1,000**

COORDINACIÓN · 23,92 / 25

Precisión cuentas	**0,911**
Recall cuentas	**0,983**
F1 cuentas	**0,946**
Grupos (B-cubed)	**0,983**

OPERACIONES ENCONTRADAS SIN MIRAR LA VERDAD

op01 · 60 cuentas

Empuja «Gracias al proyecto hay trabajo…» · cuentas de 4 días

op02 · cuentas antiguas

Empuja «Sin consulta libre e informada no hay licencia social» · la más difícil

op03 · 24 cuentas

Empuja el rumor del hospital · cuentas de 1 día, 100% nocturna

docs/VALIDACION.md · reproducible con `make run && make score`

6 min

set final: 150.000 comentarios en frío, CPU sin GPU (≈ 30 s con caché)

USD 0

de IA en la configuración por defecto

~13

llamadas LLM opcionales por corrida (una por narrativa), con caché

0 GPU

notebook común; modelo local multilingual-e5-small

ALMACENAMIENTO: DUCKDB + PARQUET

- DuckDB en proceso: cero servidores, SQL columnar, *range joins* en < 1 s.
- Parquet por etapa: el pipeline se retoma e inspecciona desde cualquier punto.
- Caché de embeddings por hash: un texto repetido nunca se re-embebe.

A MILLONES DE COMENTARIOS POR DÍA

CSV → Parquet	stream (Kafka/Redpanda) a Parquet por hora
DuckDB local	ClickHouse, **mismo SQL**
Leiden por corrida	asignación incremental por kNN
Alertas	las mismas reglas como consultas continuas

Un comando, de punta a punta: `make entrega`

Semillas fijas y orden determinístico. Sin etiquetado manual. El jurado lo puede re-correr.

VARIANTE DEL SET	TOTAL / 55	LECTURA
Completo (referencia)	**53,62**	—
Ensuciado: typos, ids duplicados, fechas rotas, filas desordenadas	**54,31**	datos sucios no lo afectan
Otras semillas (7 / 123)	**53,50 · 53,00**	estable
75% de los datos	**50,82**	degrada suave
Temas nuevos que nunca vio (sintético, narrativas)	**29,72 / 30**	agnóstico al tema
Sin respuestas: modo degradado automático	**32,64**	sin ese modo: 1,81

Set final · sin verdad

12 narrativas (3 emergentes) · **2 operaciones** (91 cuentas) · 375 s · USD 0 · dos corridas, **entrega idéntica**

37 hipótesis medidas. Las que no funcionaron, descartadas

SIN SOBREAJUSTE

Cero palabras del tema en el código. Umbrales relativos. Cada parámetro elegido por el **peor caso** sobre variantes, no por el set completo.

EXPLICABLE

Cada operación viene con su perfil (antigüedad, horario, foco) para que **una persona decida**. No juzga opiniones: juzga comportamiento.

LO QUE NO DETECTA

Campañas de cuentas antiguas que **rotan subgrupos** (ningún par coincide dos veces). Probamos 4 soluciones; lo documentamos como límite.

No toma partido En práctica encuentra una operación **a favor** del proyecto minero y otra **en contra**.

Cada criterio, con su evidencia

CRITERIO	PTS	EVIDENCIA
Calidad de narrativas	**30**	29,70 en práctica · 29,72 sobre temas que nunca vio
Detección de coordinación	**25**	23,92 en práctica · F1 0,946 · virales genuinos no pasan
Costo, escala y almacenamiento	**20**	Set final en 6 min sin GPU · USD 0 · DuckDB + Parquet · mismo SQL en ClickHouse
Robustez del pipeline	**15**	`make entrega` · datos sucios 54,31 · semillas fijas · tests de punta a punta
Claridad y visualización	**10**	Dashboard en vivo: qué circula, desde cuándo y quién lo empuja

REQUISITOS EXCLUYENTES

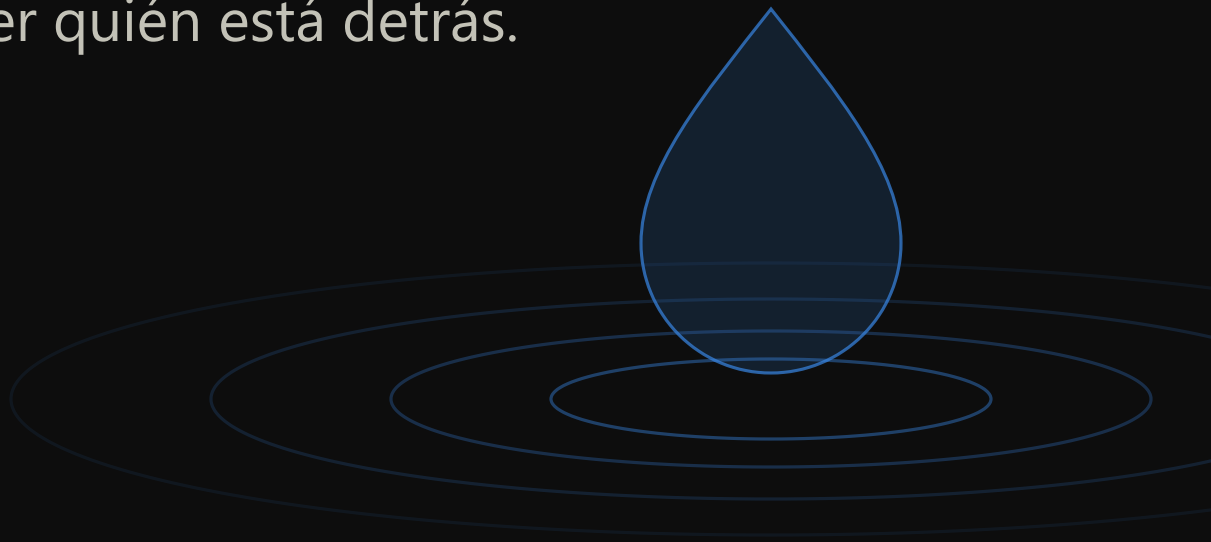
- ✓ Repo público con entrega/
- ✓ README: cómo correr, base y por qué, librerías
- ✓ Un comando sobre el set final
- ✓ Sin etiquetado manual
- ✓ Sin claves en el repo
- ✓ Gasto de IA en costo.json

Fuente: README del desafío QualyData → Puntaje y Reglas

La próxima vez que a la una de la mañana aparezca un rumor y veinticuatro cuentas salgan a empujarlo, alguien va a saber quién está detrás.

Vertiente

Qué circula, desde cuándo y quién lo empuja.



Sebastián Paz · Francisco Fernández · Antonio Chocobar